

Resumen I1 - Inferencia Estadística

Santiago Franulic

Índice

1. Estudios Estadísticos	2
2. Sesgos de Selección	3
3. Modelos Paramétricos	4
4. Estimación de Parámetros	5

1. Estudios Estadísticos

1.1: Estudio Estadístico

Proceso de recolección, análisis e interpretación de datos.

1.2: Tipos de Estudios Estadísticos

- Según el objetivo:

Analítico	Busca explicar una relación causa-efecto entre variables.
Descriptivo	Describe una población o fenómeno.

- Según el periodo de tiempo:

Transversal	Analiza en un unico momento en el tiempo.
Longitudinal	Analiza en distintos momentos en el tiempo.

- Según el control de variables:

Observacional	No interviene el investigador.
Experimental	Interviene el investigador.

- Según la dirección temporal:

Prospectivo	Analiza el fenómeno en el futuro.
Retrospectivo	Analiza el fenómeno en el pasado.

1.3: Recopilación de datos

- Muestreo → Busca describir una poblacion.
 - Probabilistico → Todos tienen una probabilidad de ser elegidos.
 - Estratificado: Se divide la poblacion en estratos y se muestrea aleatoriamente de cada estrato.
 - Conglomerados
 - Multietápico
 - No probabilistico → No todos tienen una probabilidad de ser elegidos.
- Reclutamiento → Busca explicar una relación causa-efecto entre variables.

2. Sesgos de Selección

2.1: Sesgos de Selección

Es el error de seleccionar una muestra no representativa de la población.

Principio Base

Ningún experimento es perfecto, siempre habrá sesgos segun diseño, medición, análisis y muestra.

- Sesgos transversales:
 - Cobertura incompleta
 - Participación desigual - No respuesta
 - Selección no representativa
 - Exclusion sistematica
- Sesgos longitudinales:
 - Perdida de seguimiento (sobretudo la perdida no aleatoria → sesgo del sobre-viviente)
 - Disponibilidad desigual de datos → no respuesta parcial o total

3. Modelos Paramétricos

3.1: Modelos Paramétricos

Es una familia de distribuciones de probabilidad para una variable aleatoria X :

$$\mathcal{F} = \{f(x|\theta) : \theta \in \Theta\} \quad \text{donde } \theta \in \Theta \text{ es un vector de parámetros.}$$

3.2: Familia Exponencial

Es un modelo paramétrico que se puede escribir como:

$$f(x|\theta) = h(x) \exp \left(\sum_{i=1}^s \eta_i(\theta) T_i(x) - B(\theta) \right)$$

O de forma equivalente:

$$f(x|\theta) = h(x)c(\theta) \exp \langle \eta(\theta), T(x) \rangle$$

Esta familia comparte propiedades muy útiles para la inferencia estadística.

3.3: Condiciones de Regularidad

- El espacio de parámetros Θ es un conjunto abierto.
- El soporte $\mathcal{X}$ de la variable aleatoria no depende de θ .
- Existen derivadas hasta segundo orden de $f(x|\theta)$ con respecto a θ .
- Se puede intercambiar el orden de integración y derivación.
- Para todo $\theta \in \Theta$, $\int_{\mathcal{X}} f(x|\theta) dx = 1$.

Recordatorio

El soporte de una distribución de probabilidad es el conjunto de valores que la variable aleatoria puede tomar.

4. Estimación de Parámetros

4.1: Estimadores Puntuales

Son funciones $\hat{\theta} = g(X_1, \dots, X_n)$ de la muestra $X_1, \dots, X_n$ que se utilizan para estimar el parámetro desconocido θ .

4.2: Función de Verosimilitud

Es una función que asigna un valor de probabilidad a cada posible valor del parámetro θ , dado que se ha observado una muestra $X_1, \dots, X_n$.

$$L(\theta|x_1, \dots, x_n) = f(x_1, \dots, x_n|\theta) = \prod_{i=1}^n f(x_i|\theta)$$

4.3: Estimador de Máxima Verosimilitud

Es el valor de θ que maximiza la función de verosimilitud.

$$\hat{\theta}_{EMV} = \arg \max_{\theta \in \Theta} L(\theta|x_1, \dots, x_n)$$

Metodo:

1. Calcular la función de verosimilitud $L(\theta|x_1, \dots, x_n)$.
2. Calcular la log-verosimilitud $l(\theta|x_1, \dots, x_n) = \log L(\theta|x_1, \dots, x_n)$. (Es mas facil derivar el logaritmo que la función original).
3. Derivar la log-verosimilitud con respecto a θ y igualarla a 0.
4. Resolver la ecuación para θ .

La resolución siempre es el maximo global al operar con funciones concavas (log-verosimilitud).

5. Evaluación de Estimadores Puntuales

5.1: Sesgo

Mide la exactitud de un estimador.

$$\text{Sesgo}(\hat{\theta}) = E[\hat{\theta}] - \theta$$

- $\text{Sesgo}(\hat{\theta}) > 0 \implies$ Sobreestimado
- $\text{Sesgo}(\hat{\theta}) < 0 \implies$ Subestimado
- $\text{Sesgo}(\hat{\theta}) = 0 \implies$ Insesgado

5.2: Varianza

Mide la precision de un estimador.

$$\text{Var}(\hat{\theta}) = E[(\hat{\theta} - E[\hat{\theta}])^2] = E[\hat{\theta}^2] - (E[\hat{\theta}])^2$$

5.3: Error Cuadrático Medio

Mide la exactitud y precision de un estimador.

$$\begin{aligned}\text{ECM}(\hat{\theta}) &= E[(\hat{\theta} - \theta)^2] \\ &= E[(\hat{\theta} - E(\hat{\theta})) + (E(\hat{\theta}) - \theta)]^2 \\ &= E[(\hat{\theta} - E(\hat{\theta}))^2] + 2E[(\hat{\theta} - E(\hat{\theta}))(E(\hat{\theta}) - \theta)] + E[(E(\hat{\theta}) - \theta)^2] \\ &= \text{Var}(\hat{\theta}) + 2(E(\hat{\theta}) - \theta)E[(\hat{\theta} - E(\hat{\theta}))] + (E(\hat{\theta}) - \theta)^2 \\ &= \text{Var}(\hat{\theta}) + (\text{Sesgo}(\hat{\theta}))^2\end{aligned}$$